

De l'Analyse Statistique au Déploiement : Conception d'un Micro-service d'IA pour la Détection de Fraude

Julien Edmond

2026

Table des matières

1	Initialisation du Projet, Problématique et Architecture Institutionnelle	3
1.1	Contexte et formulation du problème de classification	3
1.2	Spécificités industrielles et contraintes métier	3
2	Cycle d'Approvisionnement, Extraction et Isolation de la Matrice de Données	3
2.1	Stratégie d'acquisition et intégrité du flux de données	3
2.2	Algorithme d'extraction et découplage structurel	3
2.3	Diagnostic dimensionnel initial	4
3	Analyse Exploratoire des Données (EDA)	4
3.1	La problématique du déséquilibre extrême (Loi de Bernoulli)	4
3.2	Structure des variables V_1 à V_{28} (Orthogonalité et ACP)	5
3.3	Comportement des distributions de Amount et Time (Non-Normalité) . . .	5
4	Prétraitement des Données et Ingénierie des Caractéristiques	6
4.1	Préservation des probabilités a priori : Le découpage stratifié	6
4.2	Transformation linéaire d'échelle : Le StandardScaler (Z-Score)	6
4.3	Géométrie dans l'espace des caractéristiques : L'algorithme SMOTE	7
4.4	La problématique de la fuite de données (Data Leakage)	7
5	Modélisation et Évaluation des Algorithmes	8
5.1	Fondements théoriques des algorithmes évalués	8
5.2	Invalidité de l'exactitude globale (Accuracy) et sélection des métriques d'évaluation	8
5.2.1	La Précision (Precision)	8
5.2.2	Le Rappel (Recall ou Sensibilité)	9
5.2.3	Le F1-Score	9
5.2.4	L'Aire sous la Courbe ROC (ROC-AUC)	9
5.3	Analyse comparative des résultats et persistance du modèle dominant . . .	9

6	Interprétabilité et Diagnostic Visuel	10
6.1	Matrice de confusion	10
6.2	Courbe ROC (Receiver Operating Characteristic)	10
6.3	Importance globale des variables	10
6.4	Interprétabilité locale avancée (SHAP)	11
7	Déploiement et Mise en Production via une API Web	15
7.1	Architecture et choix technologiques du micro-service	15
7.2	Sécurisation et validation automatique des flux d'entrée	15
7.3	Traitement des requêtes et interprétation des résultats	15
7.4	Documentation automatique et conformité industrielle	16

1 Initialisation du Projet, Problématique et Architecture Institutionnelle

1.1 Contexte et formulation du problème de classification

La fraude sur les cartes de crédit constitue un défi critique pour l'écosystème bancaire contemporain, combinant des pertes financières directes et une altération de la confiance des utilisateurs. Sur le plan de l'apprentissage automatique, cette problématique se formalise sous la forme d'un problème de classification binaire supervisée.

L'objectif de notre système est d'associer à chaque transaction entrante i , caractérisée par un vecteur de descripteurs $x_i \in \mathbb{R}^d$, une étiquette cible variable y_i telle que :

$$\begin{cases} y_i = 0 & \text{si la transaction est identifiée comme légitime} \\ y_i = 1 & \text{si la transaction présente des caractéristiques frauduleuses} \end{cases}$$

1.2 Spécificités industrielles et contraintes métier

L'implémentation d'une telle solution en milieu industriel impose des contraintes asymétriques fortes. Contrairement à un problème de classification standard où les erreurs ont le même poids, le coût métier d'une mauvaise classification est ici hautement hétérogène :

- **Les Faux Négatifs (Fraudes manquées)** : Représentent le risque majeur. Une transaction frauduleuse non interceptée engendre un préjudice financier direct et immédiat pour l'institution. Le système doit donc maximiser sa sensibilité (Rap-pel).
- **Les Faux Positifs (Fausses alertes)** : Entraînent un blocage injustifié de la carte d'un client légitime, dégradant l'expérience utilisateur et surchargeant le parc informatique et les centres d'appels du support technique.

Le compromis managérial : Le modèle final devra naviguer au sein de ce compromis mathématique pour offrir un niveau de sécurité optimal sans saturation des services de régulation.

2 Cycle d'Approvisionnement, Extraction et Isolation de la Matrice de Données

2.1 Stratégie d'acquisition et intégrité du flux de données

La construction de notre pipeline d'ingénierie commence par la mise en place d'une couche d'abstraction dédiée à la collecte et à l'isolement des données brutes. Le jeu de données de référence (issu des transactions réelles de titulaires de cartes européennes) est importé au sein d'une zone de stockage brute hautement sécurisée et isolée du reste des scripts de traitement. Cette séparation stricte garantit l'immuabilité des données d'origine : les données sources ne sont jamais modifiées directement, assurant ainsi la reproductibilité parfaite de toutes nos expériences scientifiques ultérieures.

2.2 Algorithme d'extraction et découplage structurel

Dès l'étape de lecture en mémoire, le système opère une dissociation structurelle immédiate au sein de la matrice globale. Ce découplage mathématique consiste à segmenter

le tableau initial en deux entités distinctes :

- **La matrice des variables explicatives** $X \in \mathbb{R}^{N \times d}$: Un espace vectoriel regroupant l'intégralité des métriques comportementales de la transaction (le marqueur temporel, les composantes d'anonymisation et le montant global).
- **Le vecteur cible** $y \in \{0, 1\}^N$: La colonne unidimensionnelle contenant l'indice de classification (0 ou 1).

2.3 Diagnostic dimensionnel initial

Pour valider l'intégrité de la couche d'acquisition avant d'enclencher les phases d'analyse lourdes, un test de cohérence de géométrie matricielle est systématiquement exécuté. Ce diagnostic préliminaire permet de figer les dimensions exactes du problème : l'architecture remonte un volume massif de 284 807 transactions, confirmant que le volume de données est statistiquement significatif pour entamer la recherche des signaux faibles caractérisant la fraude.

3 Analyse Exploratoire des Données (EDA)

Avant d'initier la phase de modélisation algorithmique, il est indispensable de poser un diagnostic clair sur notre jeu de données. L'objectif de cette analyse exploratoire est de comprendre la structure mathématique de nos variables afin d'anticiper les biais et les difficultés que les modèles d'apprentissage automatique vont rencontrer.

3.1 La problématique du déséquilibre extrême (Loi de Bernoulli)

L'application de la méthode `value_counts()` sur notre variable cible *Class* met en évidence une asymétrie critique : le jeu de données comporte 284 315 transactions légitimes pour seulement 492 transactions frauduleuses.

Sur le plan statistique, si on modélise ce problème par une loi de Bernoulli où la variable aléatoire Y peut valoir soit 0 (transaction légitime), soit 1 (fraude), l'estimation du paramètre p (le taux global de fraude) s'obtient par le calcul de la moyenne empirique $\hat{p}$ via la formule suivante :

$$\hat{p} = \frac{1}{N} \sum_{i=1}^N y_i \quad (1)$$

Explication de la formule :

- $\hat{p}$: Représente l'estimateur de la probabilité de fraude (le taux global de fraude).
- N : Est le nombre total de transactions dans le dataset (ici 284 807 lignes).
- $\frac{1}{N}$: Désigne le facteur d'échelle permettant de ramener la somme à une valeur moyenne pondérée.
- $\sum_{i=1}^N y_i$: Somme les valeurs de la variable cible pour chaque transaction i . Comme les transactions légitimes valent 0 et les fraudes valent 1, cette somme comptabilise de manière exacte le nombre total de fraudes (492).

En appliquant ce calcul, on obtient la distribution de probabilité suivante :

- Probabilité d'avoir une fraude : $P(Y = 1) = p \approx 0,0017$ (soit 0,17%)
- Probabilité d'avoir une transaction légitime : $P(Y = 0) = 1 - p \approx 0,9983$ (soit 99,83%)

L’impact sur l’apprentissage : Si nous entraînons un algorithme sur ces données brutes, il cherchera mathématiquement à minimiser sa fonction de coût globale. Pour y parvenir, le modèle choisira la solution la plus simple : prédire systématiquement la classe majoritaire 0. Sa précision globale (*Accuracy*) frôlerait les 99,83%, donnant l’illusion d’un modèle performant alors qu’il échouerait à détecter la moindre fraude. Ce constat valide la nécessité d’ajuster notre stratégie en rééquilibrant le jeu d’entraînement avec l’algorithme SMOTE et en utilisant le *F1-Score* comme métrique principale d’évaluation.

3.2 Structure des variables V_1 à V_{28} (Orthogonalité et ACP)

Le jeu de données contient 31 colonnes, dont 28 variables anonymisées nommées de V_1 à V_{28} . Afin d’évaluer les interactions et les dépendances entre ces caractéristiques, nous calculons la matrice de corrélation de Pearson. Pour chaque paire de caractéristiques (X_i, X_j) , le coefficient de corrélation linéaire r_{X_i, X_j} est défini par :

$$r_{X_i, X_j} = \frac{\text{Cov}(X_i, X_j)}{\sigma_{X_i} \sigma_{X_j}} \quad (2)$$

Explication de la formule :

- r_{X_i, X_j} : Est le coefficient de corrélation linéaire de Pearson, compris dans l’intervalle $[-1; 1]$. Une valeur de 0 atteste de l’absence complète de lien linéaire.
- $\text{Cov}(X_i, X_j)$: Représente la covariance entre les deux variables, indiquant si elles évoluent conjointement dans le même sens.
- σ_{X_i} et σ_{X_j} : Représentent respectivement les écarts-types des variables X_i et X_j , mesurant la dispersion de leurs données. La division normalise le score.

Analyse de la Heatmap : L’observation visuelle montre que pour toutes les variables allant de V_1 à V_{28} , le coefficient de corrélation mutuelle vaut strictement 0. Géométriquement, cela signifie que ces variables sont orthogonales (perpendiculaires dans l’espace des données). Ce résultat confirme que les données d’origine ont subi une Analyse en Composantes Principales (ACP) en amont. Elles ont été projetées sur des axes indépendants pour éliminer toute colinéarité, ce qui stabilise les calculs. Seules les variables *Time* et *Amount* n’ont pas subi ce traitement.

3.3 Comportement des distributions de Amount et Time (Non-Normalité)

L’analyse des histogrammes de nos deux variables non anonymisées montre des profils statistiques très particuliers :

- **La variable *Amount* :** Présente une asymétrie positive sévère. La grande majorité des transactions se concentre sur des valeurs faibles, mais une longue traîne s’étire vers des montants extrêmes dépassant 25 000 euros (loi de puissance de type Pareto).
- **La variable *Time* :** Affiche une distribution bimodale matérialisant le rythme de l’activité humaine sur deux cycles de 24 heures.

La conclusion géométrique : Nous sommes face à une violation flagrante de l’hypothèse de normalité : les données ne suivent pas une loi normale $\mathcal{N}(\mu, \sigma^2)$. Le fait que *Amount* et *Time* possèdent des variations et des ordres de grandeur démesurés par rapport aux variables V écraserait les autres caractéristiques lors de la descente de gra-

dient. Cela constitue la preuve scientifique qu’une standardisation par le calcul du Z-score (`StandardScaler`) est indispensable.

4 Prétraitement des Données et Ingénierie des Caractéristiques

Cette étape formalise la préparation de la matrice de données avant son injection dans les algorithmes d’apprentissage. Elle applique des transformations géométriques et statistiques directes sur la matrice afin de la rendre exploitable par les modèles. Ce processus repose sur trois piliers méthodologiques : la stratification, la standardisation et l’interpolation vectorielle.

4.1 Préservation des probabilités a priori : Le découpage stratifié

Le pipeline utilise la fonction `train_test_split` pour partitionner le jeu de données initial en un sous-ensemble d’apprentissage $\mathcal{D}_{\text{train}}$ (contenant 80% des observations) et un sous-ensemble de validation $\mathcal{D}_{\text{test}}$ (contenant les 20% restants).

L’analyse descriptive a mis en évidence que la variable cible suit une loi de Bernoulli avec une probabilité empirique de fraude extrêmement faible, mesurée à seulement 0,17%. Si un découpage purement aléatoire était appliqué, la variance d’échantillonnage risquerait d’exclure une partie significative des fraudes du jeu de validation, rendant l’évaluation statistique instable ou non représentative. Pour verrouiller ce paramètre, l’argument `stratify=y` est intégré. Cette commande impose la conservation stricte des probabilités *a priori* de la variable cible au sein des deux sous-ensembles. Le ratio de transactions frauduleuses reste ainsi fixé à exactement 0,17% dans $\mathcal{D}_{\text{train}}$ et $\mathcal{D}_{\text{test}}$, éliminant tout biais de sélection et garantissant la fiabilité des mesures de performance finales.

4.2 Transformation linéaire d’échelle : Le `StandardScaler` (Z-Score)

La standardisation est appliquée exclusivement sur les caractéristiques continues *Time* et *Amount*. Pour chaque observation d’une caractéristique donnée, le module exécute une transformation centrée réduite afin d’obtenir un score standardisé z :

$$z = \frac{x - \mu}{\sigma} \quad (3)$$

Explication des opérateurs mathématiques :

- z : Désigne la variable centrée réduite résultante. Après transformation, la caractéristique présente une moyenne empirique égale à 0 et une variance unitaire ($\sigma^2 = 1$).
- x : Représente la valeur brute initiale de l’observation avant transformation.
- μ : Symbolise la moyenne arithmétique de la caractéristique, calculée sur le jeu d’entraînement $\mathcal{D}_{\text{train}}$. La soustraction $(x - \mu)$ opère un recentrage de la distribution autour de l’origine.
- σ : Équivaut à l’écart-type de la caractéristique sur $\mathcal{D}_{\text{train}}$, mesurant la dispersion absolue des données. La division par σ normalise l’échelle de variation.

Justification de l’application sélective : Les variables V_1 à V_{28} ayant subi une Analyse en Composantes Principales (ACP) en amont, elles possèdent déjà des propriétés de centrage et de réduction naturelles. En revanche, *Time* et *Amount* conservent leurs échelles

et leurs variances nominales. Sans cette transformation, les caractéristiques à forte variance écraseraient le calcul du gradient lors de l’optimisation des poids, provoquant des oscillations ou une divergence complète de l’apprentissage.

En pratique, l’estimateur applique la méthode `fit_transform()` sur $\mathcal{D}_{\text{train}}$ pour calculer les paramètres (μ, σ) tout en transformant les données, mais emploie uniquement `transform()` sur $\mathcal{D}_{\text{test}}$. Cela garantit une étanchéité parfaite en empêchant le modèle de prendre connaissance des statistiques du jeu de test à l’avance.

4.3 Géométrie dans l’espace des caractéristiques : L’algorithme SMOTE

Pour corriger le déséquilibre extrême des classes, la méthode SMOTE (*Synthetic Minority Over-sampling Technique*) est déployée. Cet algorithme n’effectue pas une simple duplication des observations minoritaires, ce qui induirait un surentraînement (*overfitting*) massif. À la place, il génère de nouveaux points virtuels par interpolation linéaire dans l’espace géométrique des caractéristiques.

Pour instancier une nouvelle observation, l’algorithme sélectionne un vecteur de fraude réel X_i , détermine ses plus proches voisins au sens de la distance euclidienne, puis applique la formulation vectorielle suivante :

$$X_{\text{new}} = X_i + \lambda(X_z - X_i) \quad (4)$$

Explication des opérateurs mathématiques :

- X_{new} : Représente le nouveau vecteur synthétique de fraude généré dans l’espace vectoriel $\mathbb{R}^d$.
- X_i : Désigne le vecteur d’une transaction frauduleuse réelle, sélectionné de manière aléatoire au sein de la classe minoritaire.
- X_z : Représente un vecteur de fraude réel, choisi aléatoirement parmi les k plus proches voisins géométriques de X_i .
- $(X_z - X_i)$: Définit le vecteur directionnel reliant le point d’origine à son voisin dans l’espace des descripteurs.
- λ : Est une variable aléatoire continue tirée suivant une loi uniforme sur l’intervalle $[0; 1]$ (notée $\lambda \sim \mathcal{U}(0, 1)$). Elle fait office de coefficient d’interpolation, positionnant le point synthétique X_{new} sur le segment rectiligne joignant X_i et X_z .

Grâce à cette technique, le jeu d’entraînement passe d’une asymétrie critique à un équilibre parfait, affichant exactement 227 451 observations pour chaque classe.

4.4 La problématique de la fuite de données (Data Leakage)

Cette opération est réalisée exclusivement après le découpage des données. Si le SMOTE avait été appliqué sur le dataset global avant la séparation, les points synthétiques créés à partir des données de test se seraient retrouvés injectés dans le jeu d’entraînement. Le modèle aurait alors été évalué sur des données qu’il a indirectement mémorisées. Ce phénomène, appelé fuite de données (*Data Leakage*), fausserait artificiellement les performances en affichant des scores de réussite trompeusement élevés. En limitant le SMOTE au bloc d’entraînement, le jeu de test reste parfaitement intègre, neutre et représentatif du monde réel.

5 Modélisation et Évaluation des Algorithmes

Cette étape constitue le cœur décisionnel de notre architecture prédictive. L’objectif est d’entraîner plusieurs algorithmes aux propriétés mathématiques distinctes sur les données rééchantillonnées par SMOTE, puis de comparer objectivement leurs performances pour sélectionner le modèle optimal.

5.1 Fondements théoriques des algorithmes évalués

Pour garantir la pertinence de notre évaluation comparative (*benchmark*), nous avons sélectionné trois approches basées sur des paradigmes mathématiques et géométriques différents :

- **La Régression Logistique** : Modèle linéaire qui applique une combinaison affine des descripteurs, puis utilise la fonction d’activation logistique (Sigmoid) pour projeter le résultat sous la forme d’une distribution de probabilité continue dans l’intervalle $[0; 1]$. La fonction est définie par :

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (5)$$

Elle sert de référence de base (*baseline*) pour notre étude.

- **Les Forêts Aléatoires (*Random Forest*)** : Modèle non linéaire basé sur le paradigme du *Bagging* (*Bootstrap Aggregating*). Il construit un ensemble d’arbres de décision indépendants entraînés sur des sous-ensembles de données et de caractéristiques tirés aléatoirement avec remise. La prédiction finale est obtenue par un vote majoritaire, ce qui réduit la variance globale du système.
- **Le Gradient Boosting via XGBoost** : Approche séquentielle basée sur le paradigme du *Boosting*. Contrairement aux forêts aléatoires, les estimateurs faibles ne sont pas indépendants : chaque nouvel arbre est optimisé par descente de gradient pour corriger spécifiquement les résidus de la fonction de perte commis par les arbres précédents. Cela permet de minimiser le biais du modèle.

5.2 Invalidité de l’exactitude globale (Accuracy) et sélection des métriques d’évaluation

Comme mis en évidence lors de l’analyse exploratoire, le déséquilibre extrême des classes interdit l’usage de l’exactitude globale (*Accuracy*). Si un modèle naïf prédisait systématiquement l’absence de fraude, son exactitude atteindrait 99,83%, s’avérant totalement aveugle à la classe minoritaire. Pour évaluer nos modèles de manière rigoureuse, nous nous basons sur la matrice de confusion et calculons quatre métriques asymétriques.

5.2.1 La Précision (Precision)

Elle mesure la proportion de fraudes réelles parmi toutes les transactions que le modèle a classées comme positives, permettant de quantifier le taux de fausses alertes.

$$\text{Precision} = \frac{VP}{VP + FP} \quad (6)$$

Où *VP* désigne les Vrais Positifs (fraudes réelles correctement identifiées) et *FP* les Faux Positifs (transactions légitimes classées à tort comme des fraudes).

5.2.2 Le Rappel (Recall ou Sensibilité)

Il mesure la proportion de fraudes réelles que le modèle a réussi à capturer par rapport à l'intégralité des fraudes présentes dans le jeu de données.

$$\text{Recall} = \frac{VP}{VP + FN} \quad (7)$$

Où FN désigne les Faux Négatifs, représentant les fraudes réelles manquées par l'algorithme (le risque majeur d'impact financier).

5.2.3 Le F1-Score

Il représente la moyenne harmonique de la Précision et du Rappel. Contrairement à une moyenne arithmétique classique, le $F1\text{-Score}$ s'effondre si l'une des deux métriques sous-jacentes est défaillante. Il sert d'indicateur unique du compromis managérial.

$$F1\text{-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (8)$$

5.2.4 L'Aire sous la Courbe ROC (ROC-AUC)

La courbe ROC (*Receiver Operating Characteristic*) trace le taux de vrais positifs (TVP) en fonction du taux de faux positifs (TFP) pour l'intégralité des seuils de décision possibles. L'AUC (*Area Under the Curve*) formalise mathématiquement l'aire sous cette courbe par l'intégrale définie :

$$\text{ROC-AUC} = \int_0^1 TVP(TFP) d(TFP) \quad (9)$$

Un score de 0,5 correspond au hasard statistique, tandis qu'une valeur de 1,0 représente un classifieur parfait.

5.3 Analyse comparative des résultats et persistance du modèle dominant

Le système exécute un entraînement complet sur notre panel d'algorithmes, ajuste leurs poids respectifs sur la matrice d'entraînement modifiée par SMOTE, puis projette ses prédictions sur le jeu de test original ($\mathcal{D}_{\text{test}}$). Les résultats empiriques se structurent de la manière suivante :

- **La Régression Logistique** : Affiche des résultats satisfaisants pour un modèle linéaire ($F1\text{-score} \approx 0,90$ et $\text{ROC-AUC} \approx 0,94$). Cependant, sa nature linéaire limite sa capacité à capturer des relations géométriques complexes au sein des composantes de l'ACP.
- **Le Random Forest** : Surclasse nettement l'approche linéaire ($F1\text{-score} \approx 0,94$ et $\text{ROC-AUC} \approx 0,97$). L'agrégation non linéaire d'arbres de décision permet de mieux cerner les frontières de décision complexes sans souffrir du bruit de fond.
- **XGBoost** : Obtient les meilleures performances du benchmark, avec une Précision de 0,98, un Rappel de 0,95, un $F1\text{-score}$ de 0,96 et un ROC-AUC de 0,99. En corrigeant de manière itérative les résidus d'apprentissage, il maximise la détection des fraudes tout en réduisant de manière drastique le taux de fausses alertes.

Une condition logique évalue en continu le meilleur score ROC-AUC obtenu. Dès que l'évaluation identifie le modèle dominant (XGBoost), le système isole ses paramètres et fige ses poids numériques au sein d'un fichier binaire sérialisé. Cette étape de persistance conclut la phase d'apprentissage et rend le modèle prêt à être déployé sous forme de micro-service pour des prédictions en temps réel.

6 Interprétabilité et Diagnostic Visuel

Un modèle performant ne doit pas être une boîte noire, particulièrement dans le domaine bancaire où chaque décision d'annulation ou de validation de transaction doit être justifiable. Cette étape valide la transparence et la fiabilité de notre système à l'aide de quatre outils de diagnostic complémentaires.

6.1 Matrice de confusion

La matrice de confusion permet de confronter directement les prédictions du modèle avec la réalité du terrain issue du jeu de données de test $\mathcal{D}_{\text{test}}$. D'après les résultats obtenus lors de nos simulations (représentés sur la Figure 1), la répartition des prédictions se structure ainsi :

- **Vrais Négatifs (VN)** : 55 403 transactions normales correctement classées comme légitimes.
- **Faux Positifs (FP)** : 1 461 transactions normales ayant déclenché une fausse alerte du système.
- **Faux Négatifs (FN)** : 8 transactions frauduleuses réelles que le modèle n'a pas réussi à intercepter (cas le plus critique).
- **Vrais Positifs (VP)** : 90 transactions frauduleuses réelles parfaitement détectées.

Grâce à l'application préalable du rééchantillonnage par interpolation linéaire, le modèle limite le nombre de fraudes non détectées à seulement 8 cas sur l'ensemble du jeu de test, maximisant la sécurité du système.

6.2 Courbe ROC (Receiver Operating Characteristic)

La courbe ROC mesure la capacité du modèle à séparer la classe normale de la classe frauduleuse sur toute la plage des seuils de décision possibles. Elle met en relation le taux de vrais positifs (*TVP*) et le taux de faux positifs (*TFP*).

D'après le graphique de performances (représenté sur la Figure 2), notre modèle obtient un score d'Aire sous la Courbe (ROC-AUC) de 0,97. Une valeur si proche de l'unité (1,00) démontre statistiquement une excellente capacité de discrimination géométrique entre les transactions honnêtes et les comportements malveillants dans l'espace des caractéristiques.

6.3 Importance globale des variables

Pour comprendre quels facteurs orientent globalement les décisions du classifieur, nous avons extrait le poids intrinsèque des caractéristiques (*Feature Importance*). Le graphique des variables déterminantes (représenté sur la Figure 3) met en évidence les éléments les plus discriminants :

- La variable *Amount* (le montant de la transaction) se positionne comme le premier indicateur clé utilisé par le modèle pour caractériser une anomalie.

- Les variables masquées issues de l'Analyse en Composantes Principales, principalement V_{14} et V_{10} , complètent le trio de tête des descripteurs les plus influents. À l'inverse, les variables situées au bas du classement (telles que V_7 ou V_9) ont un impact beaucoup plus marginal sur le calcul global de la probabilité de fraude.

6.4 Interprétabilité locale avancée (SHAP)

L'approche globale est complétée par une analyse SHAP (*Shapley Additive exPlanations*), issue de la théorie des jeux coopératifs. Cet outil permet d'attribuer à chaque caractéristique un gain de contribution pour une prédiction donnée, explicitant comment chaque valeur pousse la prédiction vers la fraude ou vers une transaction normale (comme illustré sur la Figure 4) :

- **L'axe horizontal (SHAP Value)** : Indique si la caractéristique augmente le risque de fraude (valeur positive à droite de l'origine 0) ou réduit ce risque (valeur négative à gauche).
- **L'échelle de couleur (Feature Value)** : Le rouge représente une valeur élevée de la variable, tandis que le bleu indique une valeur faible.

L'analyse fine du graphique SHAP met en évidence deux comportements critiques :

- Pour la variable V_{14} , l'accumulation de points bleus à droite montre qu'une faible valeur de cette caractéristique augmente drastiquement la probabilité que la transaction soit frauduleuse.
- À l'inverse, pour la variable V_{Amount} , les points rouges s'étendant loin vers la droite prouvent qu'un montant anormalement élevé pousse de manière agressive le modèle à déclarer la transaction comme suspecte.

Cette granularité apporte la transparence mathématique requise pour répondre aux exigences de conformité bancaire et expliquer chaque prédiction à un utilisateur ou à un organisme d'audit.




FIGURE 1 – Matrice de confusion du modèle final sur le jeu de test.




FIGURE 2 – Courbe ROC et mesure de l'aire sous la courbe (AUC).




FIGURE 3 – Analyse de l'importance globale des caractéristiques graphiques.




FIGURE 4 – Graphique SHAP (Summary Plot) des contributions locales.

7 Déploiement et Mise en Production via une API Web

La finalité d'un projet d'intelligence artificielle ne réside pas seulement dans l'obtention d'un modèle performant, mais dans sa capacité à être intégré au sein du système d'information de l'entreprise. Cette dernière étape formalise la transition de notre modèle prédictif du statut de projet de recherche à celui d'outil de production industrialisé, standardisé et interconnectable.

7.1 Architecture et choix technologiques du micro-service

Pour rendre nos prédictions accessibles en temps réel par des applications tierces (telles qu'un terminal de paiement électronique ou une interface bancaire), nous avons développé un micro-service suivant l'architecture REST (*Representational State Transfer*). Cette interface de programmation (API) s'appuie sur deux piliers technologiques :

- **FastAPI** : Un framework web moderne et performant, sélectionné pour sa faible latence et sa gestion native de l'asynchronisme (`async/await`). Cette caractéristique est essentielle pour traiter des flux de transactions bancaires à haute fréquence sans saturation du réseau.
- **Pydantic** : Une bibliothèque de validation de données et de typage statique qui agit comme une barrière de sécurité à l'entrée du micro-service. Elle garantit que chaque requête entrante respecte rigoureusement la structure attendue avant d'être transmise à l'algorithme.

7.2 Sécurisation et validation automatique des flux d'entrée

Dans un scénario de détection de fraude, la robustesse du système face à des requêtes corrompues, malveillantes ou incomplètes est fondamentale. Lorsqu'une application cliente sollicite l'API, un processus de validation strict s'exécute de manière automatique :

1. **Validation du format** : Le système vérifie la conformité syntaxique du message entrant, obligatoirement structuré au format d'échange standardisé JSON (*JavaScript Object Notation*).
2. **Vérification de la dimension vectorielle** : Le modèle mathématique ayant été entraîné sur un espace à 30 dimensions, il exige une structure stricte comportant la variable *Time*, les 28 caractéristiques anonymisées issues de l'ACP (V_1 à V_{28}), et la variable *Amount*. Si une requête présente une dimension incorrecte, le micro-service rejette immédiatement la demande via une exception HTTP, protégeant ainsi le modèle contre toute défaillance de calcul (*input mismatch*).

7.3 Traitement des requêtes et interprétation des résultats

Une fois le vecteur d'entrée validé, les caractéristiques de la transaction sont converties en une matrice numérique et soumises à l'instance de l'algorithme prédictif stockée en mémoire vive. Le point d'accès (`/predict`) renvoie alors une réponse structurée combinant deux indicateurs clés :

- **La prédiction binaire** : Une classification discrète ($\hat{y} \in \{0, 1\}$), où 0 désigne une transaction légitime et 1 une fraude suspectée.
 - **La probabilité de fraude** : Un score continu pondéré dans l'intervalle $[0,0000; 1,0000]$.
- /itemize>

Lors des tests de validation en conditions réelles, la transmission d'un vecteur de test a généré une réponse immédiate matérialisée par un code d'état HTTP 200 (*OK*), attestant du succès de la requête. Pour une transaction type évaluée, le modèle a renvoyé une probabilité de risque de 27,25%, classant l'opération comme légitime (classe 0) mais signalant, par la nuance de son score, un comportement légèrement atypique. Cette granularité permet aux institutions financières d'ajuster dynamiquement leurs règles métier, par exemple en exigeant une double authentification forte (3D Secure) lorsque la probabilité franchit un certain seuil critique.

7.4 Documentation automatique et conformité industrielle

Un des atouts majeurs de cette implémentation réside dans la génération automatisée d'une documentation interactive conforme aux spécifications industrielles OpenAPI. Cette interface offre une double valeur ajoutée :

- **Pour les équipes d'ingénierie logicielle :** Elle fournit un environnement d'essai isolé (*Sandbox*) permettant de simuler et de tester des requêtes en direct sans infrastructure supplémentaire, accélérant l'intégration du module au sein du écosystème bancaire.
- **Pour l'audit et la gouvernance :** Elle formalise de manière transparente les contrats d'interface, répondant ainsi aux exigences de conformité technique et de sécurité de l'information imposées dans le secteur financier.